

**LAPORAN MINI PROJECT CONVOLUTIONAL NEURAL NETWORK
PROGRAM STUDI SAINS DATA**

**IMPLEMENTASI CONVOLUTIONAL NEURAL NETWORK UNTUK
KLASIFIKASI CITRA RAMBU LALU LINTAS**



5221811028 - HASNA OKTAVIANI

**SEMESTER GANJIL TAHUN AKADEMIK 2025/2026
FAKULTAS SAINS & TEKNOLOGI
UNIVERSITAS TEKNOLOGI YOGYAKARTA**

DAFTAR ISI

DAFTAR ISI.....	ii
DAFTAR GAMBAR	iii
DAFTAR TABEL	iv
BAB I RANCANGAN EKSPERIMEN	1
1.1 Deskripsi Dataset	1
1.2 Pra Pemrosesan Data.....	1
1.3 Arsitektur Convolutional Neural Network.....	2
1.4 Skenario Eksperimen	3
BAB II HASIL EKSPERIMEN	6
2.1 Performa Tahap Pelatihan	6
2.2 Performa Tahap Pengujian	7
2.3 Evaluasi Model Terbaik	8
BAB III ANALISIS HASIL	10
3.1 Analisis Kelas Sulit Diklasifikasikan.....	10
3.2 Karakteristik Data pada Kelas Sulit	11
3.3 Rekomendasi Perbaikan	14

DAFTAR GAMBAR

Gambar 2. 1	Gambar 1.1 Grafik Train Loss vs Test Loss.....	8
Gambar 2. 2	Confusion Matrix.....	9
Gambar 3. 1	Top 5 Kelas Sulit Dikenali	11

DAFTAR TABEL

Tabel 1. 1 Tabel Skenario Eksperimen	4
Tabel 2. 1 Performa Model Tahap Pelatihan.....	6
Tabel 2. 2 Performa Model Tahap Pengujian.....	7
Tabel 3. 1 Perbandingan Kelas Sebenarnya dan Kelas Prediksi	12

BAB I

RANCANGAN EKSPERIMEN

1.1 Deskripsi Dataset

Secara keseluruhan, dataset GTSRB terdiri dari lebih dari 50.000 citra yang terbagi ke dalam 43 kelas rambu lalu lintas. Setiap kelas merepresentasikan jenis rambu yang berbeda, mencakup rambu peringatan, larangan, perintah, serta rambu informasi. Setiap citra hanya memiliki satu label, sehingga permasalahan yang dikaji termasuk ke dalam klasifikasi multikelas.

Dataset ini terdiri dari lebih dari 50.000 gambar rambu lalu lintas, dibagi menjadi 43 kelas yang masing-masing mewakili satu jenis rambu, seperti rambu larangan, peringatan, perintah, dan informasi. Setiap gambar memiliki satu label kelas, sehingga masalah yang ditangani termasuk klasifikasi multikelas.

Gambar pada dataset ini menunjukkan variasi pencahayaan dalam kondisi terang dan cahaya rendah. Selain itu, karena rambu diambil dari berbagai jarak dan sudut pandang, ukuran gambar tidak seragam. Dengan format file.ppm, gambar memiliki resolusi antara 15×15 piksel dan 250×250 piksel. Selain itu, ada beberapa gambar dengan rambu yang terlihat sebagian, variasi latar belakang, dan tingkat blur.

Jenis rambu lalu lintas yang terdapat pada setiap gambar adalah target klasifikasi penelitian ini. Keluaran model adalah label kelas, yang disimpan dalam bentuk numerik. Dataset ini sesuai untuk menguji kemampuan model CNN untuk mengidentifikasi dan membedakan berbagai jenis rambu lalu lintas karena memiliki banyak kelas dan kondisi data yang berbeda.

1.2 Pra Pemrosesan Data

Tahap pra pemrosesan data dilakukan untuk menyiapkan citra agar sesuai dengan kebutuhan model Convolutional Neural Network (CNN). Pada penelitian ini, pra pemrosesan mencakup penyesuaian ukuran citra, normalisasi nilai piksel, augmentasi data, serta pengelolaan label berdasarkan struktur folder dataset.

Langkah awal yang dilakukan adalah penyeragaman ukuran citra menjadi 224×224 piksel. Ukuran ini dipilih karena sesuai dengan ukuran input model

berbasis *transfer learning* yang digunakan, yaitu DenseNet121. Penyeragaman ukuran citra bertujuan agar seluruh data dapat diproses secara konsisten oleh model. Selanjutnya, dilakukan normalisasi citra menggunakan fungsi `preprocess_input`. Normalisasi ini menyesuaikan nilai piksel citra dengan karakteristik data pada model pralatih, sehingga proses pelatihan menjadi lebih stabil dan cepat.

Pada data latih, diterapkan augmentasi data untuk meningkatkan kemampuan generalisasi model. Teknik augmentasi yang digunakan meliputi rotasi ringan, *zoom*, dan *horizontal flip*. Augmentasi ini bertujuan menambah variasi data agar model lebih tahan terhadap perubahan sudut pandang dan skala objek, serta mengurangi risiko terjadinya *overfitting*.

Data latih kemudian dibagi menjadi data training dan data validation dengan rasio 80% : 20% menggunakan parameter `validation_split`. Pembagian ini dilakukan secara otomatis sehingga data validation dapat digunakan untuk memantau kinerja model selama proses pelatihan. Sementara itu, data uji diproses secara terpisah tanpa augmentasi agar evaluasi performa mencerminkan kondisi data yang sebenarnya.

Pelabelan data dilakukan secara otomatis berdasarkan struktur folder dataset. Setiap folder merepresentasikan satu kelas rambu lalu lintas, dan sistem akan mengonversi label tersebut ke dalam bentuk numerik serta *one-hot encoding*. Dengan cara ini, seluruh citra dari berbagai kelas dapat digabungkan menjadi data latih, validasi, dan uji tanpa pelabelan manual. Melalui tahapan pra pemrosesan ini, data citra yang memiliki variasi ukuran dan kondisi visual dapat distandarisasi sehingga lebih siap digunakan untuk pelatihan dan evaluasi model CNN.

1.3 Arsitektur Convolutional Neural Network

Model CNN yang digunakan pada penelitian ini dibangun dengan pendekatan *transfer learning* menggunakan arsitektur DenseNet121 sebagai model dasar. Model menerima citra berukuran $224 \times 224 \times 3$, kemudian memprosesnya melalui rangkaian layer konvolusi yang tersusun dalam beberapa *dense block*. Pada arsitektur ini, setiap layer saling terhubung melalui mekanisme *concatenate*, sehingga informasi fitur dari layer sebelumnya tetap dipertahankan dan dapat dimanfaatkan secara optimal.

Di dalam *base model* terdapat banyak layer konvolusi yang dikombinasikan dengan Batch Normalization dan fungsi aktivasi ReLU. Batch Normalization digunakan untuk menstabilkan proses pelatihan, sedangkan ReLU berfungsi memberikan non-linearitas agar model mampu mengenali pola visual yang kompleks. Selain itu, terdapat layer pooling (max pooling dan average pooling) yang berperan untuk mengurangi dimensi fitur tanpa menghilangkan informasi penting.

Sebagian besar layer pada DenseNet121 dibekukan, dan hanya sekitar 50 layer terakhir yang dilatih ulang. Strategi ini bertujuan agar model tetap memanfaatkan pengetahuan awal dari data umum, sekaligus menyesuaikan fitur dengan karakteristik citra rambu lalu lintas. Total parameter model sekitar 7,58 juta, dengan sekitar 1,62 juta parameter yang dilatih.

Pada bagian akhir, keluaran fitur diproses menggunakan Global Average Pooling untuk merangkum informasi spasial. Selanjutnya digunakan Dense layer dengan 512 neuron dan aktivasi ReLU sebagai penghubung menuju proses klasifikasi. Output layer terdiri dari 43 neuron, sesuai jumlah kelas rambu lalu lintas, dengan fungsi aktivasi Softmax. Softmax dipilih karena mampu menghasilkan probabilitas untuk setiap kelas, sehingga cocok untuk permasalahan klasifikasi multikelas.

1.4 Skenario Eksperimen

Pada penelitian ini, beberapa skenario eksperimen dilakukan untuk menentukan konfigurasi model CNN yang paling baik dalam mengklasifikasikan rambu lalu lintas. Eksperimen difokuskan pada pengujian arsitektur model, learning rate, dan fine-tuning, karena parameter tersebut berpengaruh langsung terhadap kinerja model.

Eksperimen dimulai dengan penggunaan MobileNetV2 sebagai model dasar (*baseline*) tanpa fine-tuning dengan learning rate 0,0001. Model ini digunakan sebagai acuan awal sebelum menerapkan arsitektur yang lebih kompleks.

Selanjutnya, DenseNet121 diuji tanpa fine-tuning dengan learning rate 0,0001. Pada skenario berikutnya, learning rate diturunkan menjadi 0,00001 untuk

melihat pengaruhnya terhadap kestabilan pelatihan dan kemampuan generalisasi model.

Tahap berikutnya adalah penerapan fine-tuning pada DenseNet121 dengan membuka sebagian layer untuk dilatih kembali. Selain itu, dilakukan eksperimen dengan membuka 50 layer terakhir guna menganalisis pengaruh jumlah layer yang dilatih terhadap performa model dan kemungkinan terjadinya overfitting.

Seluruh eksperimen dijalankan dengan epoch 10 dan batch size 32 agar perbandingan antar skenario tetap konsisten. Data dibagi menjadi data latih dan data validasi dengan rasio 80% : 20%, sedangkan data uji digunakan secara terpisah untuk mengevaluasi performa akhir model menggunakan akurasi dan F1-score.

Ringkasan skenario eksperimen dan hasil yang diperoleh ditampilkan pada Tabel 1.1.

Tabel 1. 1 Tabel Skenario Eksperimen

Skenario ke-	Aspek Eksperimen	Nilai
Skenario ke-1	Arsitektur model	MobileNetV2
	Learning rate	0.0001
	Epoch	10
	Batch size	32
Skenario ke-2	Arsitektur model	DenseNet121
	Learning rate	0.0001
	Epoch	10
	Batch size	32
Skenario ke-3	Arsitektur model	DenseNet121
	Learning rate	0.00001
	Epoch	10
	Batch size	32
Skenario ke-4	Arsitektur model	DenseNet121 (Fine-Tuning)
	Jumlah layer yang dilatih	Sebagian layer terakhir
	Learning rate	0.0001
	Epoch	10

	Batch size	32
Skenario ke-5	Arsitektur model	DenseNet121 (Fine-Tuning)
	Jumlah layer yang dilatih	50 layer terakhir
	Learning rate	0.0001
	Epoch	10
	Batch size	32

BAB II

HASIL EKSPERIMEN

2.1 Performa Tahap Pelatihan

Performa model CNN pada tahap pelatihan dievaluasi menggunakan training loss dan validation accuracy sesuai dengan skenario eksperimen yang telah dijelaskan pada Subbab 1.4. Kedua metrik ini digunakan untuk menilai kemampuan model dalam mempelajari data latih serta kestabilan proses pelatihan.

Model MobileNetV2 sebagai baseline menghasilkan training loss sebesar 0,48 dan validation accuracy 0,71. Selanjutnya, penggunaan DenseNet121 tanpa fine-tuning dengan learning rate 0,0001 menunjukkan penurunan training loss, namun validation accuracy belum mengalami peningkatan yang berarti. Ketika learning rate diturunkan menjadi 0,00001, pelatihan menjadi lebih stabil dan validation accuracy meningkat menjadi 0,77.

Model MobileNetV2 sebagai baseline menghasilkan training loss sebesar 0,48 dan validation accuracy 0,71. Selanjutnya, penggunaan DenseNet121 tanpa fine-tuning dengan learning rate 0,0001 menunjukkan penurunan training loss, namun validation accuracy belum mengalami peningkatan yang berarti. Ketika learning rate diturunkan menjadi 0,00001, pelatihan menjadi lebih stabil dan validation accuracy meningkat menjadi 0,77.

Ringkasan performa tahap pelatihan untuk setiap skenario eksperimen disajikan pada Tabel 2.1.

Tabel 2. 1 Performa Model Tahap Pelatihan

Skenario	Arsitektur Model	Learning Rate	Training Loss	Validation Accuracy	Keterangan
1	MobileNetV2	0.0001	0.48	0.71	Performa dasar, stabil
2	DenseNet121	0.0001	0.35	0.69	Peningkatan belum signifikan
3	DenseNet121	0.00001	0.31	0.77	Pelatihan lebih stabil

4	DenseNet121 (Fine-Tuning)	0.0001	0.28	0.83	Performa terbaik saat training
5	DenseNet121 (Fine-Tuning 50 Layer)	0.0001	0.25	0.85	Indikasi awal overfitting

2.2 Performa Tahap Pengujian

Tahap pengujian dilakukan menggunakan data testing untuk menilai kemampuan generalisasi model CNN. Evaluasi difokuskan pada akurasi uji (test accuracy) dan F1-score, karena metrik tersebut mampu menggambarkan keseimbangan kinerja model dalam mengklasifikasikan setiap kelas rambu lalu lintas.

Hasil pengujian menunjukkan bahwa MobileNetV2 sebagai model baseline memperoleh akurasi uji sebesar 0,62 dengan F1-score 0,58, yang menandakan performa masih terbatas. DenseNet121 dengan learning rate 0,00001 memberikan peningkatan performa dengan akurasi uji 0,74 dan F1-score 0,70. Performa terbaik dicapai oleh DenseNet121 dengan fine-tuning, yang menghasilkan akurasi uji 0,80 dan F1-score 0,76. Meskipun fine-tuning 50 layer terakhir menghasilkan akurasi lebih tinggi, konfigurasi ini menunjukkan indikasi overfitting sehingga kurang stabil dibandingkan fine-tuning parsial.


Tabel 2. 2 Performa Model Tahap Pengujian

Skenario	Arsitektur Model	Learning Rate	Test Accuracy	F1-Score	Keterangan
1	MobileNetV2	0.0001	0.62	0.58	Baseline
2	DenseNet121	0.0001	—	—	Data uji tidak dievaluasi
3	DenseNet121	0.00001	0.74	0.7	Generalisasi meningkat
4	DenseNet121 (Fine-Tuning)	0.0001	0.8	0.76	Performa paling seimbang

5	DenseNet121 (Fine-Tuning 50 Layer)	0.0001	0.82	0.79	Indikasi overfitting
---	--	--------	------	------	-------------------------


2.3 Evaluasi Model Terbaik

Berdasarkan seluruh rangkaian eksperimen yang telah dilakukan, model terbaik yang dipilih adalah DenseNet121 dengan fine-tuning parsial. Model ini menunjukkan performa yang paling seimbang antara tahap pelatihan dan pengujian. Pada tahap pelatihan, model mencapai akurasi data latih sebesar $\pm 0,90$, sedangkan pada tahap pengujian diperoleh akurasi data uji sebesar 0,80 dengan nilai F1-score sebesar 0,76. Perbedaan nilai akurasi tersebut masih berada dalam batas yang wajar dan menunjukkan kemampuan generalisasi yang baik.



Gambar 2. 1 Gambar 1.1 Grafik Train Loss vs Test Loss

Grafik akurasi dan loss memperlihatkan bahwa akurasi training dan validation meningkat secara konsisten hingga akhir epoch. Kurva validation mengikuti tren kurva training tanpa terjadi penurunan performa di akhir pelatihan. Selain itu, training loss dan validation loss sama-sama menurun secara stabil, yang menandakan proses pembelajaran berjalan efektif dan tidak mengalami ketidakseimbangan antara data latih dan data validasi. Pola ini menunjukkan bahwa model mampu mempelajari fitur penting tanpa menghafal data latih secara berlebihan.



Gambar 2. 2 Confusion Matrix

Hasil confusion matrix memperkuat temuan dari grafik performa. Mayoritas prediksi berada pada diagonal utama, yang menunjukkan bahwa sebagian besar citra rambu lalu lintas berhasil diklasifikasikan ke kelas yang benar. Kesalahan klasifikasi masih ditemukan pada beberapa kelas tertentu, terutama pada rambu yang memiliki kemiripan visual, namun jumlahnya relatif kecil dibandingkan prediksi yang benar. Secara keseluruhan, distribusi ini mencerminkan kinerja model yang stabil dan konsisten.

Berdasarkan evaluasi grafik metrik pelatihan, grafik loss, serta confusion matrix, tidak ditemukan indikasi overfitting yang signifikan pada model terbaik. Selisih antara performa data latih dan data uji masih terkendali, dan tidak terjadi peningkatan validation loss pada epoch akhir. Dengan demikian, DenseNet121 dengan fine-tuning parsial dapat disimpulkan sebagai model yang paling optimal untuk klasifikasi citra rambu lalu lintas pada penelitian ini.

BAB III

ANALISIS HASIL

3.1 Analisis Kelas Sulit Diklasifikasikan

Berdasarkan hasil **confusion matrix**, beberapa kelas rambu lalu lintas menunjukkan tingkat kesalahan klasifikasi yang lebih tinggi dibandingkan kelas lainnya. Kelas-kelas tersebut ditandai dengan masih munculnya nilai prediksi yang cukup signifikan di luar diagonal utama, yang berarti citra dari kelas tersebut sering diprediksi sebagai kelas lain.

Pola kesalahan yang paling sering muncul terjadi pada kelas-kelas rambu yang memiliki **kemiripan visual**, baik dari segi **bentuk dasar**, **warna dominan**, maupun **simbol di dalam rambu**. Misalnya, rambu dengan bentuk lingkaran dan warna merah cenderung saling tertukar, begitu pula rambu berbentuk segitiga dengan simbol yang mirip. Hal ini menunjukkan bahwa model masih mengalami kesulitan dalam membedakan detail visual halus antar kelas yang secara semantik berbeda namun secara tampilan hampir serupa.

Selain itu, variasi kualitas citra juga berpengaruh terhadap tingkat kesalahan. Perbedaan pencahayaan, sudut pengambilan gambar, serta ukuran rambu dalam citra dapat membuat detail visual menjadi kurang jelas. Pada beberapa kelas, jumlah data yang relatif lebih sedikit juga menyebabkan model memiliki referensi yang terbatas saat proses pelatihan, sehingga meningkatkan kemungkinan kesalahan prediksi.

Meskipun demikian, kesalahan ini tidak mendominasi keseluruhan hasil klasifikasi. Sebagian besar prediksi tetap berada pada kelas yang benar, sehingga performa model secara umum masih dapat dikategorikan baik. Kelas yang sulit diklasifikasikan lebih disebabkan oleh karakteristik visual data, bukan karena kelemahan model secara keseluruhan.

3.2 Karakteristik Data pada Kelas Sulit

Berdasarkan analisis citra dengan kesalahan klasifikasi tertinggi, terlihat bahwa kesalahan paling sering terjadi pada kelas-kelas rambu yang memiliki kemiripan visual yang tinggi, meskipun model memberikan nilai kepercayaan yang sangat besar.




Gambar 3. 1 Top 5 Kelas Sulit Dikenali

Pada Gambr 3.1, citra dengan kelas sebenarnya 2 (Speed Limit 50) diprediksi sebagai kelas 9 (No Passing) dan kelas 1 (Speed Limit 30) dengan confidence di atas 0,99. Kesalahan serupa juga terjadi pada kelas 4 (Speed Limit 70) yang diprediksi sebagai kelas 1, serta kelas 30 (Beware of Ice/Snow) yang diprediksi sebagai kelas 11. Hal ini menunjukkan bahwa model cenderung lebih mengandalkan bentuk dan warna rambu dibandingkan detail simbol atau angka yang lebih spesifik.

Jika diperhatikan kembali pada Tabel 3.1, citra pada kelas sebenarnya menunjukkan ciri visual utama yang saling mirip, terutama dari segi bentuk rambu dan warna dominan.

Tabel 3. 1 Perbandingan Kelas Sebenarnya dan Kelas Prediksi

Kelas Sebenarnya		Kelas Prediksi	
True : 2 Pred : 9 Conf : 0.99 	Kelas: 2		Kelas: 9
True : 4 Pred : 1 Conf : 0.99 	Kelas: 4		Kelas: 1
True : 30 Pred : 11 Conf : 0.99 	Kelas: 30		Kelas: 11
True : 39 Pred : 38 Conf : 0.99 	Kelas: 39		Kelas: 38

	Kelas: 2		Kelas: 1
---	----------	--	----------

Berdasarkan tabel 3.1 yang sulit diklasifikasikan, kelas-kelas dengan tingkat kesalahan tinggi memiliki ciri visual utama yang saling mirip, sehingga sulit dibedakan oleh model. Pada kelompok rambu batas kecepatan (kelas 1, 2, dan 4), ciri yang paling dominan adalah bentuk lingkaran dengan tepi merah dan latar putih. Perbedaan antar kelas hanya terletak pada angka di bagian tengah, yang pada beberapa citra tampak buram, berukuran kecil, atau terpengaruh pencahayaan. Akibatnya, citra dari kelas 2 (Speed Limit 50) sering diprediksi sebagai kelas 1 (Speed Limit 30) atau bahkan sebagai kelas 9 (No Passing), karena model lebih menangkap pola global dibandingkan detail angka.

Karakteristik serupa juga terlihat pada rambu Beware of Ice/Snow (kelas 30) yang diprediksi sebagai kelas 11. Kedua rambu sama-sama berbentuk segitiga dengan tepi merah, sehingga perbedaan simbol di bagian tengah menjadi sulit dikenali ketika citra memiliki kontras rendah atau pencahayaan kurang optimal. Selain itu, pada rambu perintah arah Keep Left (kelas 39) dan Keep Right (kelas 38), kesalahan terjadi karena kedua kelas memiliki warna biru dan bentuk lingkaran yang identik, dengan perbedaan utama hanya pada arah panah. Jika citra diambil dari sudut tertentu atau kualitas citra menurun, arah panah menjadi kurang jelas dan mudah tertukar.

Jika dibandingkan dengan kelas lain yang memiliki simbol unik dan kontras tinggi, seperti rambu dengan ikon besar atau warna yang sangat berbeda, kelas-kelas di atas memiliki fitur pembeda yang lebih halus. Hal inilah yang menyebabkan kelas tersebut lebih sulit diklasifikasikan. Contoh citra pada gambar menunjukkan bahwa kombinasi kemiripan visual, kualitas citra, dan detail simbol yang kecil menjadi faktor utama penyebab kesalahan klasifikasi pada kelas-kelas tersebut.

3.3 Rekomendasi Perbaikan

Berdasarkan hasil analisis, salah satu penyebab utama kesalahan klasifikasi adalah model terlalu bergantung pada fitur global seperti bentuk dan warna rambu, sehingga kurang sensitif terhadap detail kecil seperti angka atau arah simbol. Oleh karena itu, perbaikan dapat dilakukan dengan mendorong model untuk lebih fokus pada area penting rambu, misalnya melalui augmentasi yang menekankan bagian tengah citra atau dengan menggunakan *cropping* sederhana. Pendekatan ini relatif mudah diterapkan dan sesuai dengan keterbatasan eksperimen pada mini project.

Selain itu, hasil eksperimen menunjukkan bahwa fine-tuning yang terlalu dalam tidak selalu menghasilkan performa yang lebih baik dan justru dapat memicu overfitting. Hal ini mengindikasikan bahwa pemilihan jumlah layer yang dilatih perlu disesuaikan dengan karakteristik data. Dari mini project ini dapat dipelajari bahwa peningkatan performa tidak selalu dicapai dengan menambah kompleksitas model, melainkan dengan strategi pelatihan yang tepat dan pemahaman terhadap karakteristik data. Secara keseluruhan, DenseNet121 dengan fine-tuning parsial sudah memberikan keseimbangan yang baik antara akurasi dan stabilitas.